

بسم الله الرحمن الرحيم

فاطمه اثباتی

گزارش سوم – مهندسی داده

دی ماه ۱۴۰۳

بر اساس صحبت های گفته شده بر اساس مسیر پیش رفته و قدم به قدم را اینجا مینویسیم و تمرکز خود را روی چالش ها و نحوه و مسیر درست کردن آن ها میگذاریم. در نتیجه نوشته های هر قسمت به سه بخش

چالش و راه حل: چالش ها و راه حل هایی که با آن ها برخورد کردیم تا به جواب نهایی برسیم. نتیجه: آخرین و درست ترین مسیری که به جواب رسیده و یک راه حل شسته رفته از آن تشکیل شده است. سوال: سوال ها و مسایل بازی که در حین اجرا با آن مواجه شده اما به دلیل کمبود وقت یا پررنگ نبودن مسئله به بعدا موکول شده اند.

تقسیم بندی شده اند.


دانلود و پیکربندی Rocky Linux


چالش ها و راه حل ها:

1 . چالش خطای virtual box

اگر از فایل iso خود مطمئن هستید که به درستی دانلود شده و به خطای checksum یا anaconda برخورد کردید نیاز است در virtual box از قسمت مربوط به ماشین settings/storage/controller: IDE آن فایلی که unattended هست را حذف کرده و دوباره فایل iso را اضافه کنید. منبع راه حل:

<https://sangkyu519.medium.com/install-rhel-with-virtualbox-fix-checksum-error-daba1bf566b0>






2. چالش storage

اگر به صورت دیفالت storage را پیش ببرید ممکن است در حین نصب برنامه ها با مشکل فضا روبرو بشید — درست است که بعد از نصب os نیز میشود پارتیشن بندی کرد و تغییرات داد اما اگر قبلش به شکل صحیح تر پیش بروید با مشکلات کمتر روبرو خواهید شد.

منبع راه حل:

<https://www.youtube.com/watch?v=xPz15XnDNC4>



3. چالش بدون gui (مشکل کپی) با استفاده از moboXterm


منبع راه حل: آقای الله دادی را خداوند خیر بی کران دهد.

4. چالش ssh

منبع راه حل:

[https://dev.to/developertarun/easy-way-to-ssh-into-virtualbox-machine-any-os-just-x-steps-](https://dev.to/developertarun/easy-way-to-ssh-into-virtualbox-machine-any-os-just-x-steps-5d9i)

5d9i



نتیجه:

<https://phoenixnap.com/kb/rocky-linux-virtualbox>
<https://customer.acecloudhosting.com/index.php/knowledgebase/129/How-to-SSH-terminal-through-Mobaxterm-and-PuTTY-in-Windows-.html>

سوال: تفاوت اصلی این نسخه لینوکس با بقیه چیست؟ چرا این نسخه انتخاب شده است؟

دانلود و نصب Hadoop

چالش ها و راه حل ها:

چالش ۱: مشکل ران نشدن یا سریع خاموش شدن resource manager و node manager

```
[esbati@vbox ~]$ jps
83075 SecondaryNameNode
82861 DataNode
84221 Jps
82732 NameNode
[esbati@vbox ~]$ ^C
[esbati@vbox ~]$
```

```
2025-01-02 19:53:35,381 ERROR org.apache.hadoop.yarn.server.resourcemanager.ResourceManager: Error starting ResourceManager
java.lang.ExceptionInInitializerError
    at com.google.inject.internal.cglib.reflect.$FastClassEmitter.<init>(FastClassEmitter.java:67)
    at com.google.inject.internal.cglib.reflect.$FastClass$Generator.generateClass(FastClass.java:72)
    at com.google.inject.internal.cglib.core.$DefaultGeneratorStrategy.generate(DefaultGeneratorStrategy.java:25)
    at com.google.inject.internal.cglib.core.$AbstractClassGenerator.create(AbstractClassGenerator.java:216)
    at com.google.inject.internal.cglib.reflect.$FastClass$Generator.create(FastClass.java:64)
    at com.google.inject.internal.BytecodeGen.newFastClass(BytecodeGen.java:204)
    at com.google.inject.internal.ProviderMethod$FastClassProviderMethod.<init>(ProviderMethod.java:256)
    at com.google.inject.internal.ProviderMethod.create(ProviderMethod.java:71)
    at com.google.inject.internal.ProviderMethodsModule.createProviderMethod(ProviderMethodsModule.java:275)
    at com.google.inject.internal.ProviderMethodsModule.getProviderMethods(ProviderMethodsModule.java:144)
    at com.google.inject.internal.ProviderMethodsModule.configure(ProviderMethodsModule.java:123)
    at com.google.inject.spi.Elements$RecordingBinder.install(Elements.java:340)
    at com.google.inject.spi.Elements$RecordingBinder.install(Elements.java:349)
    at com.google.inject.AbstractModule.install(AbstractModule.java:122)
    at com.google.inject.servlet.ServletModule.configure(ServletModule.java:52)
    at com.google.inject.AbstractModule.configure(AbstractModule.java:62)
    at com.google.inject.spi.Elements$RecordingBinder.install(Elements.java:340)
    at com.google.inject.spi.Elements.getElements(Elements.java:110)
    at com.google.inject.internal.InjectorShell$Builder.build(InjectorShell.java:138)
    at com.google.inject.internal.InternalInjectorCreator.build(InternalInjectorCreator.java:104)
    at com.google.inject.Guice.createInjector(Guice.java:96)
    at com.google.inject.Guice.createInjector(Guice.java:73)
    at com.google.inject.Guice.createInjector(Guice.java:62)
    at org.apache.hadoop.yarn.webapp.WebApps$Builder.build(WebApps.java:417)
    at org.apache.hadoop.yarn.webapp.WebApps$Builder.start(WebApps.java:465)
    at org.apache.hadoop.yarn.server.resourcemanager.ResourceManager.startWebApp(ResourceManager.java:1389)
    at org.apache.hadoop.yarn.server.resourcemanager.ResourceManager.serviceStart(ResourceManager.java:1498)
    at org.apache.hadoop.service.AbstractService.start(AbstractService.java:194)
    at org.apache.hadoop.yarn.server.resourcemanager.ResourceManager.main(ResourceManager.java:1699)
Caused by: java.lang.reflect.InaccessibleObjectException: Unable to make protected final java.lang.Class java.lang.ClassLoader.defineClass(java.lang.String,byte[],int,int,java.security.ProtectionDomain) throws java.lang.ClassFormatError accessible: module java.base does not "opens java.lang" to unnamed module @58a94022
    at java.base/java.lang.reflect.AccessibleObject.checkCanSetAccessible(AccessibleObject.java:354)
    at java.base/java.lang.reflect.AccessibleObject.checkCanSetAccessible(AccessibleObject.java:297)
    at java.base/java.lang.reflect.Method.checkCanSetAccessible(Method.java:188)
```

حل مشکل با استفاده از تغییر ساختار \$HADOOP_HOME/etc/hadoop/yarn-site.xml
تاکید روی yarn.nodemanager.env-whitelist

```
<configuration>
  <!-- Site specific YARN configuration properties -->
  <property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  </property>
  <property>
```

```

        <name>yarn.nodemanager.env-whitelist</name>
        <value>JAVA_HOME,HADOOP_COMMON_HOME,HADOOP_HDFS_HOME,HADOOP_CONF_DIR,CLASSPATH_PREPEND_DISTCACHE,HADOOP_YARN_HOME,HADOOP_HOME,PATH,LANG,HADOOP_MAPRED_HOME</value>
    </property>
    <property>
        <name>yarn.nodemanager.resource.memory-mb</name>
        <value>4096</value>
    </property>
    <property>
        <name>yarn.scheduler.minimum-allocation-mb</name>
        <value>2048</value>
    </property>
    <property>
        <name>yarn.nodemanager.vmem-pmem-ratio</name>
        <value>2.1</value>
    </property>
</configuration>

```

و همچنین نیاز به تغییر optional های هدوپ برای کانفیگ جاوا نیز برمیخوریم.

کمی تغییر در دستورات به دلیل استفاده از rhel

نتیجه:

https://github.com/fatemesbati/data-engineer/blob/main/hadoop/task-1/Hadoop_Installation.md

سوال: رقبای هدوپ چه ابزارهای دیگری هستند؟ چرا هدوپ انتخاب شده است؟
خواندن و مطالعه معماری Hadoop از کتاب

دانلود و نصب Hive

چالش ۲: اگر با استفاده از جاوا ۸ پیش برویم همه چیز عالی خواهد بود اما اگر با استفاده از java 21 و ورژن های بالاتر جاوا پیش برویم به مشکلات عدیده ای بر میخوریم:

```

[esbati@vbox hive]$ bin/schematool -dbType derby -initSchema --hiveconf hive.classpath=$HIVE_HOME/lib/*
Exception in thread "main" java.lang.ClassNotFoundException: org.apache.hive.beeline.HiveSchemaTool
    at java.base/java.net.URLClassLoader.findClass(URLClassLoader.java:445)
    at java.base/java.lang.ClassLoader.loadClass(ClassLoader.java:593)
    at java.base/java.lang.ClassLoader.loadClass(ClassLoader.java:526)
    at java.base/java.lang.Class.forName0(Native Method)
    at java.base/java.lang.Class.forName(Class.java:534)
    at java.base/java.lang.Class.forName(Class.java:513)
    at org.apache.hadoop.util.RunJar.run(RunJar.java:321)
    at org.apache.hadoop.util.RunJar.main(RunJar.java:241)

```

کاملاً سیستم بالا آوردن hive با مشکل روبرو خواهند شد و متأسفانه راه حلی مناسبی جز استفاده از snapshot استفاده شده یافت نشد.

نتیجه:

با کمی تغییرات این مسیر و تغییر به ورژن ۸ به طور کامل و صحیح بالا می آید و از mysql در روند نیز استفاده شد و توانسته شد تست خروجی گرفته شود.

https://github.com/fatemesbati/data-engineer/blob/main/hadoop/task-1/Hive_Installation.md

```
hive> DESCRIBE FORMATTED test_table;
OK
# col_name      data_type      comment
id              int
name            string

# Detailed Table Information
Database:       default
OwnerType:      USER
Owner:          esbati
CreateTime:     Sat Jan 04 21:11:47 EST 2025
LastAccessTime: UNKNOWN
Retention:      0
Location:       hdfs://localhost:9000/usr/local/hive/warehouse/test_table
Table Type:     MANAGED_TABLE
Table Parameters:
    bucketing_version      2
    numFiles                1
    numRows                0
    rawDataSize            0
    totalSize              20
    transient_lastDdlTime  1736043143

# Storage Information
SerDe Library:   org.apache.hadoop.hive.serde2.lazy.LazySimpleSerDe
InputFormat:     org.apache.hadoop.mapred.TextInputFormat
OutputFormat:    org.apache.hadoop.hive.ql.io.HiveIgnoreKeyTextOutputFormat
Compressed:      No
Num Buckets:     -1
Bucket Columns:  []
Sort Columns:    []
Storage Desc Params:
    field.delim           ,
    serialization.format  ,
Time taken: 0.457 seconds, Fetched: 32 row(s)
```

دانلود دستی و کانفیگ کردن hue

```
ModuleNotFoundError: No module named 'daemon'
Running '/home/esbati/hue/build/env/bin/python /home/esbati/hue/build/env/bin/hue migrate --fake-initial' with None
Traceback (most recent call last):
  File "/home/esbati/hue/build/env/bin/hue", line 33, in <module>
    sys.exit(load_entry_point('desktop', 'console_scripts', 'hue')())
  File "/home/esbati/hue/build/env/bin/hue", line 25, in importlib_load_entry_point
    return next(matches).load()
  File "/usr/lib64/python3.9/importlib/metadata.py", line 86, in load
    module = import_module(match.group('module'))
  File "/usr/lib64/python3.9/importlib/_init_.py", line 127, in import_module
    return _bootstrap.gcd_import(name[level:], package, level)
  File "<frozen importlib._bootstrap>", line 1030, in gcd_import
```

دانلود و نصب hue

ابتدا پکیج و لایبرری های مورد نیاز را دانلود میکنیم:

<https://docs.gethue.com/administrator/installation/dependencies>
<https://github.com/cloudera/hue?tab=readme-ov-file>

PYTHON:

```
sudo dnf install python3.9-devel -y  
sudo pip3 install python-daemon
```

```
sudo ln -sf /usr/bin/python3 /usr/bin/python  
sudo ln -s /usr/bin/pip3 /usr/bin/pip
```

```
export PYTHON_VER=python3.9 in ~/.bashrc
```

OS:

```
sudo yum install ant asciidoc cyrus-sasl-devel cyrus-sasl-gssapi cyrus-sasl-plain gcc gcc-c++ krb5-devel  
libffi-devel libxml2-devel libxslt-devel make mysql mysql-devel openldap-devel python-devel sqlite-devel  
gmp-devel
```

NODEJS:

```
curl -sL https://rpm.nodesource.com/setup_20.x | sudo bash -  
sudo yum install -y nodejs
```

```
npm install --global npm
```

سپس برای ساختن از سورس کد اقدام میکنیم:

```
# <install OS dependencies>  
git clone https://github.com/cloudera/hue.git  
cd hue  
make apps  
build/env/bin/hue runserver
```

چالش ها و راه حل ها:

هنگام ساخت بعضی از ماژول ها یافت نمیشوند که مجبور میشویم حالت محیطی را اکتیو کرده و آن را دانلود کنیم و دوباره به ادامه مسیر بپردازیم.

```

    from aws.conf import is_enabled as is_s3_enabled
File "/home/esbati/hue/desktop/libs/aws/src/aws/conf.py", line 25, in <module>
    from desktop.lib.idbroker import conf as conf_idbroker
File "/home/esbati/hue/desktop/core/src/desktop/lib/idbroker/conf.py", line 19, in <module>
    from requests_kerberos import HTTPKerberosAuth
ModuleNotFoundError: No module named 'requests_kerberos'
make[1]: Leaving directory '/home/esbati/hue/apps'
make[1]: Entering directory '/home/esbati/hue'
"PYTHON_VER is python3.9."
"SYS_PYTHON is /usr/bin/python3.9."
"ENV_PYTHON is /home/esbati/hue/build/env/bin/python3.9."
"SYS_PIP is /home/esbati/.local/bin/pip3.9."
"ENV_PIP is /home/esbati/hue/build/env/bin/python3.9 /home/esbati/hue/build/env/bin/pip."

```

source /home/esbati/hue/build/env/bin/activate

pip install <package-name>

deactivate

make apps

مثال:

pip install python-daemon

pip install pytz

pip install Django

pip install configobj

pip install requests-kerberos

pip install boto

.....

یا اینکه:

export ROOT=/home/esbati/hue

pip install -r base_requirements.txt

pip install -r requirements.txt

سوال: از کجا دقیقاً دیتاست TCP-DS باید گرفته شود؟؟!!

سوال: دیدن صفحات وب در سیستم مبدا به واسطه port forwarding؟